

多模态融合收益阈值模型

研究规划文档

基于当前 OpenBG-IMG 分析型论文的下一阶段方法化转向方案

文档概览

文档目的：将当前“揭示多模态收益存在边界”的分析型工作，升级为“提出收益预测与自适应启用机制”的方法型研究计划。

核心方向：学习一个 protocol-aware 的 gain predictor，判断在给定 query / relation / 模态条件下是否值得启用 multimodal fusion，并用阈值机制控制最终的专家选择或分支混合。

适用场景：与现有 Gate-only、Residual-only、Full Model、统一训练框架、子群分析流程保持兼容，尽量基于现有实验资产快速落地。

1. 研究背景与转向动因

当前论文已经较系统地证明：在 OpenBG-IMG 的现有 protocol 下，多模态收益并不是全局均匀存在的，而是受到 target-side modality regime、relation condition 以及 branch interaction 的共同制约。换言之，已有工作已经回答了“多模态什么时候有用、为什么其收益难以转化为整体优势”这一分析问题。

但从投稿角度看，当前稿件的主要问题在于：结论停留在“揭示收益边界”，尚未进一步提出相应的解决方案。因此，下一阶段最合理的转向，并不是完全推翻现有工作，而是顺着已有证据继续推进，将“收益边界”显式转化为一个可学习、可决策、可验证的方法问题。

新的核心问题可以表述为：如果 multimodal gain 本身是条件性的、可预测的，那么模型是否应当在所有 query 上一律启用 fusion？更合理的答案应当是：只在预计有收益时启用 fusion，在预计无收益甚至有害时回退到结构专家或轻量语义专家。

2. 新研究目标与论文定位

2.1 总体目标

构建一个“多模态融合收益阈值模型（multimodal gain threshold model）”，在 query、relation、模态质量与结构不确定性等条件下，预测某次融合是否值得启用，并据此执行自适应的专家选择或分支混合。

2.2 论文定位

这篇新论文不再仅仅强调“多模态收益有边界”，而是进一步提出：在 role-conditioned missing-modality protocol 下，多模态收益是可以被预测和选择性激活的。因此，系统应从 always-fuse 走向 selective-fuse。

2.3 预期贡献

- (1) 问题层面：将 bounded multimodal gain 从经验现象上升为一个显式的决策问题。
- (2) 方法层面：提出 gain predictor + threshold router 的轻量化方法，与现有 MMKGC 框架兼容。
- (3) 实验层面：用 protocol-aware evaluation 验证模型是否真正把 fusion 用在“该用”的地方。
- (4) 分析层面：进一步解释何种特征决定融合收益，以及固定全局混合权重为何不足。

3. 总体技术路线

建议采用“双专家 + 收益预测器 + 阈值路由器”的总体结构，而不是重新设计一个很重的新模型。这样既能最大化复用现有代码与实验框架，也能让新方法的贡献点更清晰。

模块	建议实现	作用说明
Fusion Expert	优先复用 Gate-only 或 Full Model 的 fusion branch	提供 multimodal 表达能力，作为可选增强路径。
Structural Expert	优先使用 Residual-only；必要时可增加 ComplEx 参照	在结构占优或缺图条件下提供稳定表现。
Gain Predictor	MLP / Logistic / XGBoost 等轻量分类器	预测当前 query 是否值得启用 fusion。
Threshold Router	硬阈值或软阈值路由	将预测结果转化为最终的专家选择或分数混合。

3.1 核心推理流程

- 输入一个待预测 query（例如 (h, r, ?) 或 (?, r, t)）。
- 同时计算 fusion expert 与 structural expert 的候选打分或中间表示。
- 从 query、relation、模态质量、结构不确定性和分支冲突中抽取 gain features。
- gain predictor 输出一个收益概率 p_gain，表示“启用 fusion 的预期收益”。
- threshold router 根据阈值 τ 决定：只用 structural、只用 fusion，或执行条件化混合。

3.2 推荐的最终形式

最推荐的主线形式是 score-level routing：先分别得到两个 expert 的打分，再做条件化选择或加权。这样实现最简单，训练风险最低，也便于做可解释分析。相较之下，representation-level routing 更复杂，适合作为后续扩展而不是首轮主结果。

4. 模型设计建议

4.1 专家模块

Fusion Expert 建议优先采用 Gate-only，而不是直接用当前 Full Model 作为首选 fusion expert。原因在于：当前 Full Model 内部已经包含 residual-dominant 的全局混合偏好，如果再在外层叠加 router，解释会变得不够干净。Gate-only 更适合代表“纯融合能力”。

Structural Expert 建议优先采用 Residual-only，因为它在当前 setting 下表现最强，也最能代表“结构补偿/结构回退”的稳定路径。ComplEx 则可以作为额外对照，以说明路由并不是只对内部家族模型有效。

4.2 Gain Predictor 的输入特征

(a) 模态质量特征

- has_img / no_img；missing-image replacement 标记。
- 文本嵌入与图像嵌入的余弦相似度。
- 图像嵌入范数、文本嵌入范数、跨模态差异度。
- 可选：图像质量分数、CLIP 对齐得分、异常样本分数。

(b) 关系相关性特征

- relation id / relation embedding。
- relation 所属类别：visual_relations、weak_visual_relations、ambiguous_material_relations。
- relation 的历史 multimodal gain 均值或 fusion 胜率。
- relation 在 head_has_img / head_no_img / tail_no_img 下的收益分布。

(c) 任务复杂性与结构不确定性特征

- structural expert 的 top-1 与 top-2 score gap。
- 候选分布熵、预测置信度、rank margin。
- relation 的实体度数统计、one-to-many / many-to-one 倾向。
- query direction (head prediction / tail prediction)。

(d) 分支冲突与可靠性特征

- fusion score 与 structural score 的差值。

- gate mean、gate entropy、两分支表示间的 cosine disagreement。
- 可选：局部的 mix tendency、projection gradient proxy。

4.3 收益标签 (gain label) 定义

为了训练 gain predictor，需要把“是否值得融合”定义成一个监督信号。最稳妥的方法，是先固定两个 experts，再在 train/dev 上离线构造 gain label。

- 二分类标签：若 fusion expert 在某 query 上相较 structural expert 带来显著正收益，则标为 1；否则标为 0。
- 收益度量可用 reciprocal-rank gain、correct-answer margin gain，或 top-k hit 改善。
- 建议加入一个小 margin δ ，避免把几乎持平的样本错误标成 gain-positive。
- 禁止基于 test 集反推 gain label，避免信息泄漏。

4.4 路由策略

建议至少实现以下三种形式，并以硬阈值版本作为主结果：

路由 (Rule-based) ——例如“有图才允许 fusion”或“仅在特定 relation 上启用 fusion”，作为弱基线。

硬路由 (Hard Threshold) ——当 $p_{\text{gain}} > \tau$ 时选 fusion，否则选 structural。

混合 (Soft Threshold) ——将 p_{gain} 转为连续权重 α ，实现平滑过渡，作为增强版本。

5. 训练与实现流程

5.1 两阶段训练方案

阶段 A：先独立训练并固定两个 experts，确保 fusion expert 与 structural expert 均稳定可复现。

阶段 B：离线抽取 gain features，构造 gain label，训练 gain predictor。

阶段 C：冻结 experts，仅训练 router，并接回最终打分流程。

阶段 D (可选)：进行轻量 joint fine-tuning，验证是否还能进一步提升。

5.2 实现优先级建议

- 第一优先级：Logistic Regression / 小型 MLP + Hard Threshold。
- 第二优先级：加入 relation prior、uncertainty feature、branch conflict feature。
- 第三优先级：soft routing、representation-level routing、joint fine-tuning。
- 不建议一开始就做复杂端到端训练，否则很容易增加变量、削弱论证。

6. 实验设计

6.1 主结果比较

- Always-Structural (Residual-only) 。
- Always-Fusion (Gate-only) 。
- Global Mixed Model (当前 Full Model 或固定混合版本) 。
- Rule-based Selector 。
- Learned Threshold Router (主方法) 。

6.2 必须保留的 protocol-aware evaluation

你当前论文最大的优势之一，就是已经建立起了协议感知的分析框架。因此，新论文绝不能只报 overall MRR，而应继续保留并强化以下评估视角。

- 子群评估：head_has_img、head_no_img、tail_no_img 。
- relation-group 评估：visual_relations、weak_visual_relations、ambiguous_material_relations 。
- 行为分析：在哪些条件下 router 选择 fusion，在哪些条件下回退 structural 。
- coverage-performance 曲线：阈值越高，fusion 覆盖率越低，但单次融合收益是否更高 。

6.3 Selector 本身的评估

- AUC、F1、Balanced Accuracy、Precision / Recall 。
- gain-positive 与 gain-negative 样本的不平衡处理 。
- Calibration 分析：预测的 p_gain 是否与真实收益概率一致 。
- Feature importance：哪些特征最能决定“值不值得融合” 。

6.4 消融实验

- 只用 has_img 的 heuristic 。
- has_img + relation prior 。
- 再加入 modal quality 特征 。
- 再加入 uncertainty / branch conflict 特征 。
- hard routing vs soft routing；score-level vs representation-level 。

7. 风险点与应对策略

风险点	可能问题	建议应对
-----	------	------

退化为简单 heuristic	模型最后只是学会“有图就融合，没图就不用”。	必须证明 relation、quality、uncertainty 等特征也提供了额外价值。
收益标签噪声大	fusion 与 structural 的差距很小，导致标签不稳定。	引入 margin δ ；只对高置信样本监督；必要时做 soft label。
实验目标设得过高	若 learned routing 无法大幅超过 Residual-only，论文说服力受限。	把主贡献写成“减少 harmful fusion、保留 localized gain”，而不是“全面击败强结构 baseline”。
端到端训练过重	训练不稳定，变量太多，难以解释提升来源。	先做冻结 experts 的两阶段方案，把可解释性和可复现性放在首位。

8. 论文结构建议

- Introduction：从 bounded multimodal gain 出发，提出“是否应当总是启用 fusion”的新问题。
- Protocol-aware Observation：简洁回顾 OpenBG-IMG 的 role-modality asymmetry 与既有发现。
- Method：提出 gain predictor + threshold router。
- Experts and Training Pipeline：说明两个 experts、gain label、routing strategy。
- Experiments：主结果、selector 评估、子群分析、relation-group、消融。
- Discussion：强调 selective activation 的价值，而不是追求不加条件的全局多模态优势。

9. 建议的执行顺序

第 1 步：固定 Gate-only 与 Residual-only，导出每个 dev query 的 RR_fuse、RR_struct、 ΔRR 及相关特征。

第 2 步：先训练一个最简单的 gain predictor，验证它能否区分 gain-positive 与 gain-negative 样本。

第 3 步：实现 Hard Threshold Router，先跑 overall + subgroup + coverage curve。

第 4 步：补充 rule-based baseline 与 feature ablation。

第 5 步：在结果稳定后，再考虑 soft routing 与轻量 joint fine-tuning。

最终建议

结论建议：这项工作更适合做成一篇“小而硬”的方法论文，而不是一个过大、过泛的新框架论文。

最有说服力的贡献表述应当是：在 role-conditioned missing-modality protocol 下，multimodal gain 是可预测的，因此 fusion 不应默认总开，而应被选择性激活。